Projecte de laboratori: Model predictiu d'Esquizofrènia Resistent al Tractament (TRS)

Berta Vidal Gómez

Introducció a l’Aprenentatge Automàtic

Desembre 2025

Introducció

Aquest informe documenta el desenvolupament d'un model d'aprenentatge automàtic per a la predicció d'esquizofrènia resistent al tractament (TRS) a partir de dades clíniques multimodals. El projecte té com a objectiu principal aplicar tècniques d'aprenentatge supervisat per construir un classificador binari que, donats paràmetres de laboratori, marcadors genètics, característiques de neuroimatge i dades demogràfiques, pugui predir amb precisió la categoria diagnòstica del pacient. A més, aquest model ha de ser capaç de generalitzar correctament a noves dades no vistes durant l'entrenament.

Context del problema:

L'esquizofrènia és un trastorn mental greu que afecta aproximadament l'1% de la població mundial. Tot i que existeixen tractaments farmacològics efectius, al voltant del 30% dels pacients presenten resistència al tractament (TRS), definida com la persistència de símptomes psicòtics malgrat l'ús adequat d'antipsicòtics convencionals. Amb l'objectiu d'adaptar correctament el tractament d'aquests pacients i millorar el seu pronòstic, és clau identificar els pacients amb risc de desenvolupar TRS.

Des d'una perspectiva de machine learning, aquest problema presenta diversos reptes metodològics: alta dimensionalitat de les dades, desbalanceig de classes, possible presència de valors missings, necessitat de gestionar variables categòriques i numèriques de manera conjunta, i el requeriment d'interpretar les prediccions en un context clínic.

Per abordar aquests reptes, en aquest projecte he implementat i comparat tres models diferents: un Support Vector Machine (SVM), un XGBoost i una regressió logística custom implementada amb descens de gradient per mini-batch. En aquest informe, detallo i justifico tot el procés que s'ha seguit fins a assolir el model predictor final; des de l'exploració i preparació de les dades, selecció del millor classificador i documentació.

1. Anàlisi i preprocessat de dades

1.1. Anàlisi estadístic de les variables

He realitzat una exploració estadística inicial de totes les variables del dataset mitjançant la funció describe() de pandas, que proporciona mesures de tendència central i dispersió. El dataset conté un total de 26 variables: 24 numèriques i 2 categòriques (*Ethnicity* i *CYP2D6_metabolic_phenotype*).

A continuació, detallo l'anàlisi de dues variables representatives que considero rellevants per la tasca de classificació:

***Age*:** La variable *Age* presenta una distribució amb mitjana de 26.04 anys i desviació estàndard de 10.01 anys, amb valors que oscil·len entre 13 i 64 anys (Taula 1). El rang interquartílic (IQR) situa el 50% central dels pacients entre 19 i 31 anys, amb una mediana de 25 anys, indicant una població relativament jove. L'histograma de la Figura 1 mostra una distribució asimètrica cap a la dreta, amb una concentració màxima de pacients al voltant dels 20-25 anys i una cua llarga cap a edats avançades. Aquesta distribució reflecteix el perfil demogràfic típic d'esquizofrènia, amb major incidència en adults joves.

***Initial_response*:** La variable *Initial_response*, que mesura la resposta inicial al tractament en una escala de 0 a 100, presenta una mitjana de 41.84 i una desviació estàndard elevada de 30.16, reflectint una alta variabilitat entre pacients (Taula 1). El rang interquartílic mostra que el 25% dels pacients tenen resposta pobra (≤10.1), el 50% tenen resposta moderada (mediana: 38.2) i el 75% assoleixen fins a 72.3 punts de resposta. La Figura 1 revela una distribució trimodal amb tres pics diferenciats: un primer grup amb resposta molt baixa (0-10, aproximadament 900 pacients), un segon grup amb resposta moderada-alta (35-50, aproximadament 600 pacients) i un tercer grup amb resposta excel·lent (70-90, aproximadament 400 pacients). Aquesta distribució trimodal suggereix l'existència de tres perfils clínics clars i diferenciats de resposta al tractament inicial. Aquesta variable és clínicament rellevant ja que la resposta inicial sovint prediu la resposta a llarg termini i, per tant, podria ser un dels predictors més forts per diferenciar TRS de NTRS.

Variable	count	mean	std	min	25%	50%	75%	max
Age	9000.0	26.04	10.01	13.0	19.0	25.0	31.0	64.0
Initial_response	9000.0	41.84	30.16	0.0	10.1	38.2	72.3	100.0

Taula 1: Estadístiques descriptives de les variables *Age* i *Initial_response*.

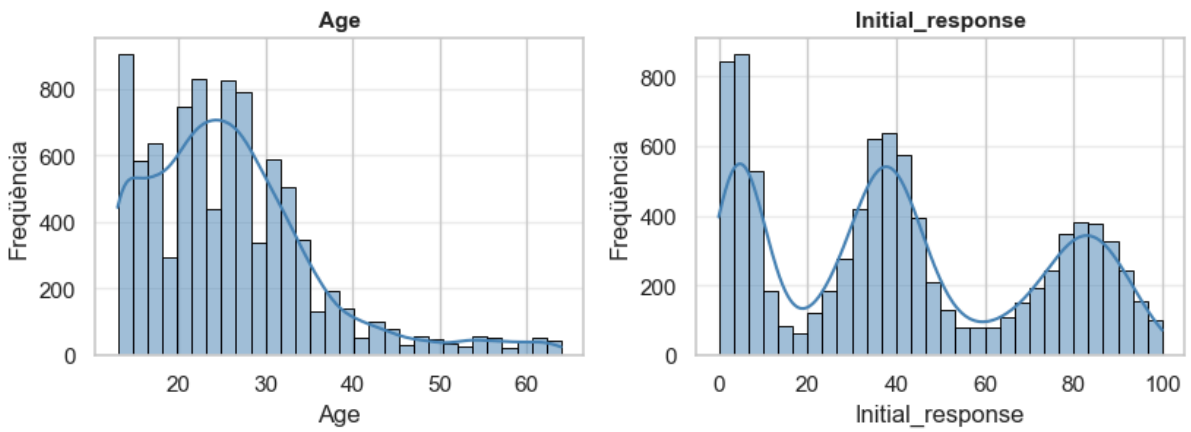

Figura 1: Histogrames de les distribucions de les variables *Age* i *Initial_response*.

1.2. Estudi del balanceig de la classe objectiu

He analitzat la distribució de la variable objectiu TRS en el conjunt d'entrenament proporcionat. Tal com es mostra a la Figura 2, el dataset presenta un desequilibri moderat entre les dues classes: la classe NTRS (no resistents al tractament, codificada com a 0) representa el 68.47% del total amb 6,162 observacions, mentre que la classe TRS (resistents al tractament, codificada com a 1) constitueix el 31.53% amb 2,838 observacions. Aquesta distribució resulta en una ràtio de desequilibri de 2.17:1 a favor de la classe majoritària NTRS.

Malgrat aquest desequilibri, he decidit mantenir la distribució natural de les dades sense aplicar tècniques de balanceig no vistes a classe. Per una banda, el desequilibri observat representa la proporció real de casos TRS en la població clínica estudiada. En contextos mèdics, preservar aquesta distribució natural garanteix que el model reflecteixi la prevalença real de la condició i generalitzi adequadament en un context clínic real, on les noves dades segueixen aquesta mateixa proporció. En conseqüència, el desequilibri es gestionarà durant el modelatge amb paràmetres adequats i mètriques específiques que avaluen correctament el rendiment en ambdues classes independentment de les seves proporcions, evitant el biaix de l'accuracy cap a la classe majoritària.

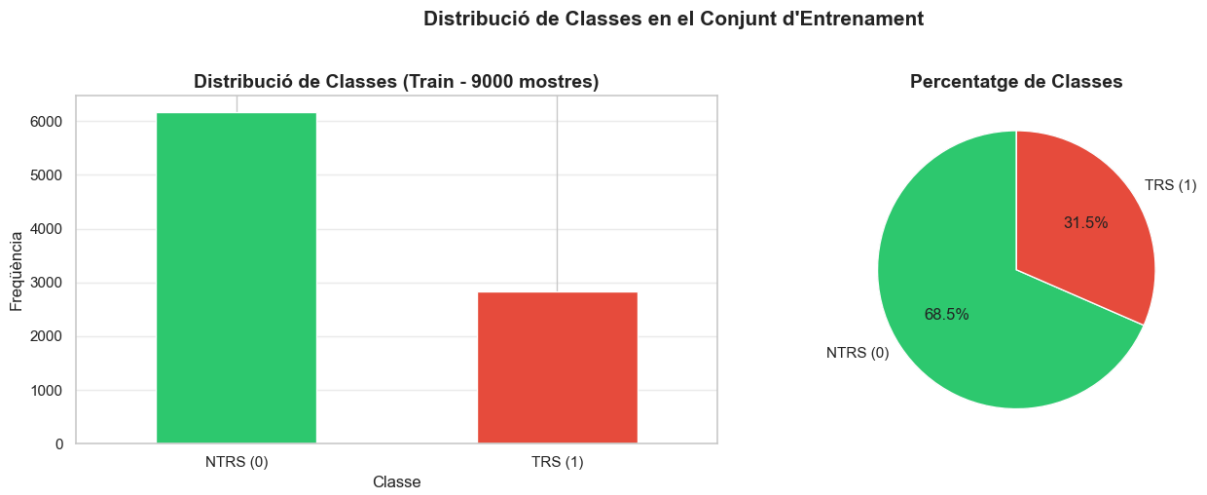

Figura 2: El diagrama de barres i el de sectors reflecteixen la freqüència de cada categoria de la variable TRS en el conjunt d'entrenament.

1.3. Gestió de missings

L'anàlisi de valors absents (Figura 3) revela que 8 de les 26 variables presenten missings amb percentatges que oscil·len entre el 0.01% i el 32.64%. Les variables més afectades són paràmetres de laboratori clínic: *Alkaline_phosphatase* (32.64%), *Glucose* (29.10%), *Triglycerides* (27.26%), *Lymphocyte_count* (22.12%) i *Neutrophil_count* (22.06%). La resta de variables mostren missings residuals inferiors al 1.5%.

He decidit aplicar imputació per mediana en variables numèriques i per moda en variables categòriques. La mediana és l'opció més adequada amb la presència d'Outliers (detectats a la

Secció 1.4), evitant que els valors imputats estiguin esbiaixats per valors extrems. Aquesta estratègia és preferible a l'eliminació de files, que suposaria perdre aproximadament el 40% del dataset. La imputació s'ha executat després del particionament i els paràmetres d'imputació (mediana/moda) es calculen exclusivament amb el conjunt de train, garantint que cap informació del conjunt de validació ha influït en el procés.

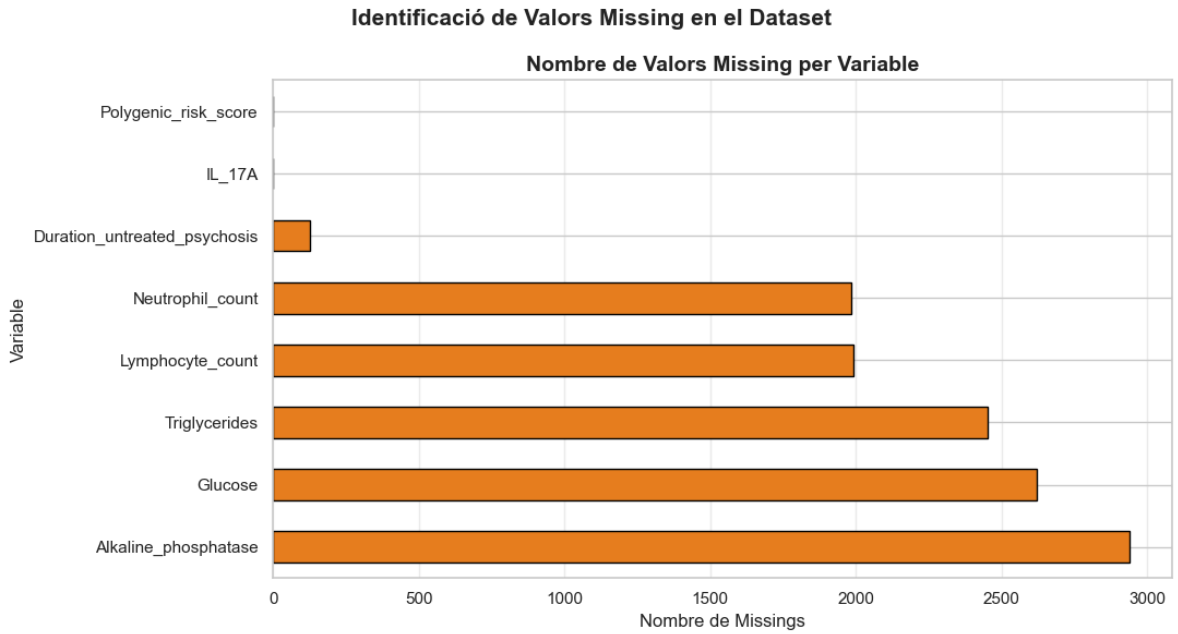

Figura 3: Diagrama de barres horitzontals del nombre de valors missing per variable.

1.4. Identificació i tractament d'outliers

He aplicat el mètode IQR (Interquartile Range) per identificar outliers en les variables numèriques contínues, definint com a valors extrems aquells que cauen fora de l'interval [Q1 - 1.5×IQR, Q3 + 1.5×IQR]. S'ha detectat outliers en 14 de les 18 variables analitzades (Figura 4), destacant *Duration_untreated_psychosis* (7.23%, 651 outliers), *Age* (4.00%, 360 outliers), *Polygenic_risk_score* (1.39%, 125 outliers) i *Ki_associative_striatum* (0.92%, 83 outliers). Les variables amb menor presència d'outliers són *Glucose* (0.18%), *Triglycerides* (0.24%), *Alkaline_phosphatase* (0.26%), Lymphocyte_count (0.29%) i *Neutrophil_count* (0.36%). Notablement, *Initial_response* i *Prior_antipsychotics* no presenten cap outlier segons aquest criteri. He visualitzat aquests valors atípics amb diagrames de caixa (boxplots), que permeten visualitzar la dispersió i identificar punts que queden fora dels llindars esperats.

He optat per mantenir tots els outliers sense modificació. En dades clíniques, valors extrems sovint representen casos patològics reals amb alta rellevància diagnòstica enlloc d'errors de mesura. Per exemple, valors alts en Duration_untreated_psychosis (fins a 125 mesos segons el límit superior) poden indicar pacients amb psicosi no tractada durant períodes prolongats, potencialment associats amb pitjor pronòstic i major risc de TRS.

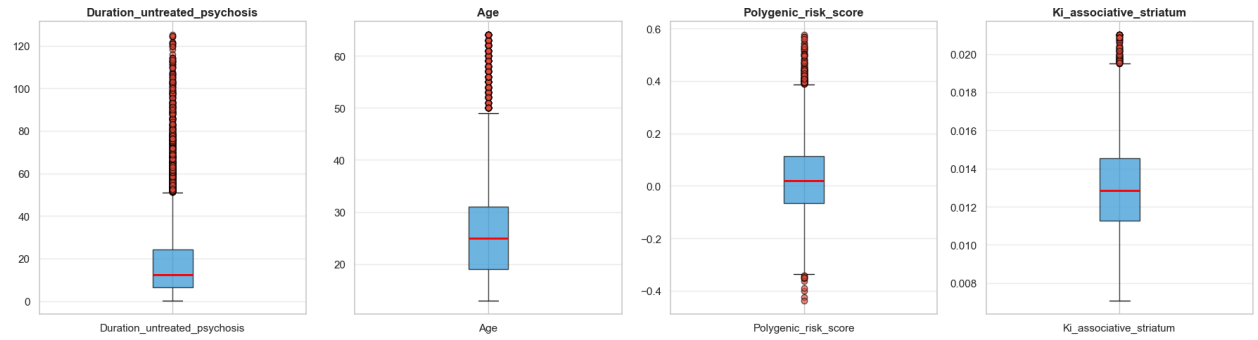

Figura 4: Identificació de valors atípics mitjançant el mètode IQR per a les variables numèriques amb major incidència d'outliers detectades en el dataset.

1.5. Recodificació de variables

El dataset conté 2 variables categòriques que requereixen transformació numèrica per ser utilitzades pels models: *Ethnicity* amb 4 categories (Caucasian, Asian, Hispanic, African) i *CYP2D6_metabolic_phenotype* amb 4 categories (Extensive, Intermediate, Ultrarapid, Poor).

He aplicat one-hot encoding amb drop='first' com a estratègia de recodificació. Aquesta tècnica crea una columna binària independent per a cada categoria (excepte una de referència), on 1 indica presència i 0 absència de la categoria. Aquesta tècnica és necessària perquè ambdues variables són nominals sense ordre natural, per tant, utilitzar label encoding introduiria relacions ordinals i de distància falses. Mantenir una categoria de referència implícita evita redundància i garanteix que les columnes resultants no siguin linealment dependents, evitant singularitat en models lineals.

La transformació s'executa després del particionament i la imputació dins d'un pipeline, assegurant que les categories apreses provenen exclusivament del conjunt de train. Com a resultat, les dues variables originals generen 3 columnes binàries cadascuna, incrementant la dimensionalitat del dataset de 26 variables originals a 30 variables finals.

1.6. Particionament del dataset i justificació de les mides

He particionat el conjunt de train original (9,000 observacions) en dues noves particions: train (6,300 observacions, 70%) i validation (2,700 observacions, 30%). Aquesta divisió és necessària perquè el conjunt d'avaluació extern de Kaggle (1,000 observacions) no conté la variable objectiu TRS i només pot utilitzar-se per generar el fitxer submission.csv final, sense possibilitat d'avaluar el rendiment dels models durant el desenvolupament. Per tant, es necessari un conjunt de validation independent per ajustar hiperparàmetres i seleccionar el millor model abans de la submissió.

He aplicat estratificació (stratify=y_train_full) per garantir que ambdues particions mantenen proporcions idèntiques de classes: 68.46% NTRS i 31.54% TRS al train, i 68.48% NTRS i 31.52% TRS al validation (Taula 2).

La distribució 70/30 és estàndard i garanteix un equilibri adequat: el 70% proporciona suficients dades per entrenar models complexos, mentre que el 30% assegura un conjunt de validation prou gran (2,700 mostres) per obtenir estimacions fiables de les mètriques de rendiment durant l'optimització d'hiperparàmetres.

Totes les transformacions ja explicades s'executen després d'aquest particionament, calculant paràmetres exclusivament amb el conjunt de train. D'aquesta manera, el conjunt de validation simula dades futures no vistes durant l'entrenament, proporcionant una estimació realista del rendiment de generalització.

Partició	**Mida**	**Percentatge**	**NTRS (%)**	**TRS (%)**
Train	6,300	70.0%	68.46%	31.54%
Validation	2,700	30.0%	68.48%	31.52%
Total	10,000	100%	68.47%	31.53%

Taula 2: Mida i distribució de la classe de les diferents particions.

2. Preparació de variables

2.1. Normalització de variables

He aplicat normalització amb StandardScaler a les 18 variables numèriques contínues després del particionament i la imputació. Aquest mètode transforma cada variable restant la seva mitjana i dividint per la desviació estàndard, resultant en distribucions amb mitjana 0 i desviació estàndard 1. Les 6 variables binàries originals es mantenen en escala 0/1, igual que les variables binàries derivades del one-hot encoding aplicat posteriorment a les 2 variables categòriques.

La normalització és necessària per evitar que variables contínues amb escales grans dominin sobre les petites en models basats en distàncies com SVM. Per exemple, *Triglycerides* té valors entre 40-395 mentre que *Ki_whole_striatum* oscil·la entre 0.008-0.020. Sense normalització, els algorismes interpretarien incorrectament que diferències numèriques grans tenen major importància predictiva.

2.2. Anàlisi de variables categòriques i variable objectiu

Per analitzar la relació entre les dues variables categòriques (Ethnicity i CYP2D6_metabolic_phenotype) i la variable objectiu TRS, s'ha generat diagrames de barres agrupats i taules de freqüències.

Ethnicity mostra una distribució homogènia de TRS al voltant del 31-32% en totes les categories (Caucasian 31.79%, African 31.36%, Asian 31.42%, Hispanic 30.43%), indicant que l'origen ètnic no presenta una relació forta amb la resistència al tractament. Per altra banda, *CYP2D6_metabolic_phenotype* mostra lleugeres diferències entre categories. Els metabolitzadors Intermediate presenten la major proporció de TRS (34.83%), mentre que Ultrarapid mostren la menor (29.47%). Tot i aquesta variabilitat, les diferències són molt petites i suggereixen que el fenotip metabòlic té una influència baixa en la resposta al tractament.

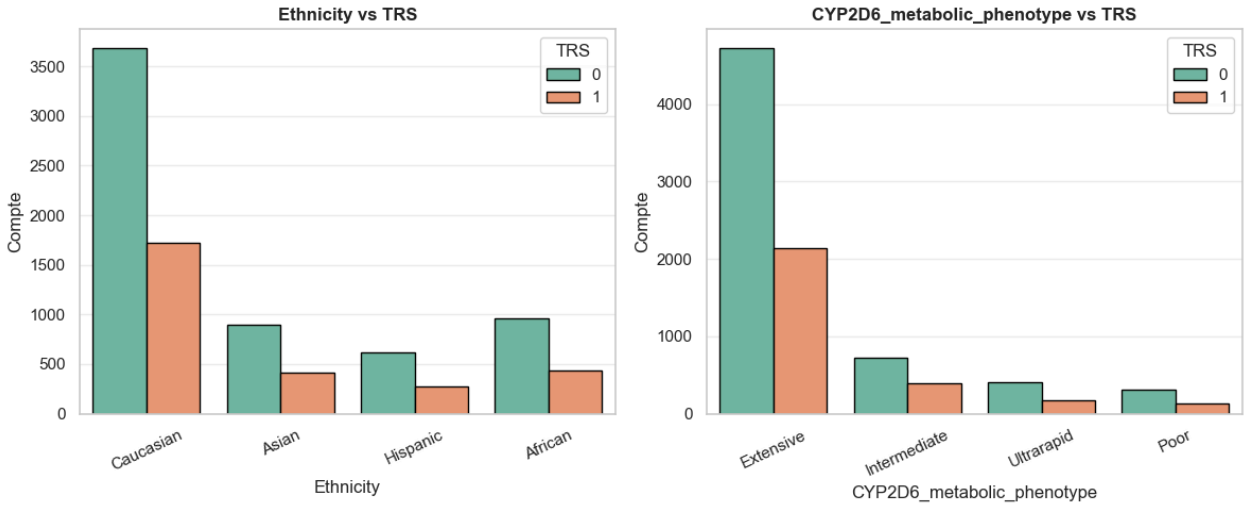

Figura 5: Gràfics de barres comparatius mostren la distribució de la freqüència per a *Ethnicity* i *CYP2D6_metabolic_phenotype* segons la resistència al tractament (TRS). Permeten observar visualment si determinats grups presenten una major proporció de pacients resistents.

2.3. Eliminació de variables numèriques redundants (Correlació).

He analitzat la matriu de correlació entre variables numèriques per identificar redundàncies i variables amb alta multicolinealitat. L'anàlisi revela que *Ki_whole_striatum* i *Ki_associative_striatum* presenten una correlació extremadament alta de 0.964, indicant que contenen essencialment la mateixa informació. A més, ambdues variables mostren correlacions similars amb la variable objectiu TRS (0.042 i 0.040 respectivament), confirmant que són redundants per a la predicció. He decidit eliminar *Ki_associative_striatum* i mantenir *Ki_whole_striatum* perquè aquesta última captura informació més general. La resta de variables mostren correlacions moderades entre elles ($|r| < 0.8$).

Destaca que *Initial_response* és la variable amb major correlació negativa amb TRS (-0.213), indicant que pacients amb resposta inicial baixa tenen major probabilitat de desenvolupar resistència al tractament.

2.4. Estudi de dimensionalitat mitjançant PCA.

S'ha avaluat la necessitat de reduir dimensions mitjançant Anàlisi de Components Principals (PCA) aplicat exclusivament sobre les 18 variables numèriques contínues normalitzades. El

scree plot mostra que els primers components capturen proporcionalment més variància, però la distribució és relativament uniforme sense un colze pronunciat que indiqui un punt òptim de tall. L'anàlisi quantitatiu revela que calen 11 components per retenir el 80% de variància (35.3% reducció), 13 per al 90% (23.5% reducció), i 15 per al 95% (11.8% reducció).

He decidit no aplicar PCA per tres raons principals. Primer, la reducció per mantenir el 95% de variància és mínima (només 3 variables, 11.8%). En segon lloc, el dataset inclou 12 variables binàries (6 originals i 6 resultants del one-hot encoding) que no s'han analitzat amb PCA perquè aquest mètode està dissenyat per variables contínues. Finalment, mantenir les variables originals permet interpretar clínicament quins factors específics contribueixen a predir TRS.

El dataset final conté 29 variables (17 contínues + 12 binàries), preservant tota la informació disponible.

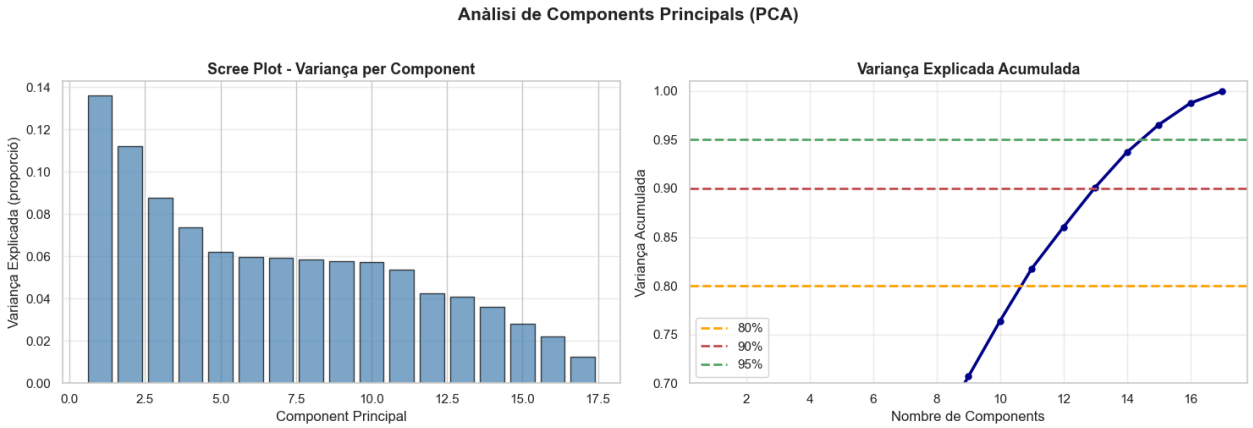

Figura 7: El scree plot (esquerra) detalla la proporció de variància explicada per cada component individual, mentre que el gràfic de la dreta mostra la variància acumulada en funció del nombre de components.

3. Definició de models

Aquest apartat descriu l'entrenament i validació de tres models de classificació supervisada per predir esquizofrènia resistent al tractament (TRS): Support Vector Machine (SVM), XGBoost, i una regressió logística implementada amb descens de gradient per mini-batch.

3.1. Metodologia d'avaluació i definició de mètriques

S'ha seleccionat **Macro F1-Score** com a mètrica principal d'optimització per la seva adequació en datasets desbalancejats. Aquesta mètrica calcula la mitjana aritmètica del F1-Score de cada classe independentment, tractant NTRS i TRS amb la mateixa importància malgrat la diferència de freqüència (68% NTRS, 32% TRS):

$$Macro\ F = \frac{F1NTRS + F1TRS}{2}$$

On cada F1 per classe es defineix com: $F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}$

Aquesta elecció garanteix que el model no aconsegueixi puntuacions altes simplement predint sempre la classe majoritària NTRS, forçant-lo a mantenir un bon rendiment en ambdues classes.

Mètriques complementàries:

- Recall (Sensibilitat): Proporció de pacients TRS detectats correctament. Mètrica clínicament prioritària per minimitzar falsos negatius (pacients TRS no detectats).
- Precision: Proporció de prediccions TRS que són correctes.
- Accuracy: Proporció total de prediccions correctes. Menys rellevant pel desbalanceig.
- ROC-AUC: Àrea sota la corba ROC, avalua capacitat de discriminació independent del threshold.
- PR-AUC: Àrea sota la corba Precision-Recall.

Estratègia de validació i cerca del millor model

Els hiperparàmetres de cada model es seleccionen maximitzant Macro F1-Score en cross-validation. En concret, s'utilitza Stratified 5-Fold Cross-Validation durant GridSearchCV i RandomizedSearchCV. Aquest mètode divideix el conjunt d'entrenament (6300 mostres) en 5 particions (folds) mantenint la proporció original de classes (68% NTRS, 32% TRS) en cada fold. El procés itera 5 vegades: a cada iteració, 4 folds s'utilitzen per entrenar i 1 per validar, rotant fins avaluar totes les particions.

Aquest enfocament proporciona una estimació fiable del rendiment, reduint la variància causada per una sola partició train/validation. La estratificació garanteix que cada fold mantingui la proporció de classes. Finalment, es fa una cerca exhaustiva per ajustar el threshold òptim de classificació amb el millor model seleccionat.

3.2. Model 1: Support Vector Machine (SVM)

Les Support Vector Machines (SVM) són models de classificació que busquen l'hiperplà òptim que maximitza el marge entre classes. L'objectiu és trobar la frontera de decisió que separa les classes amb el màxim marge possible, on els support vectors són els punts més propers a aquesta frontera i defineixen el model. El model implementat és un soft-margin SVM, que permet errors de classificació controlats pel paràmetre C. Per capturar relacions no lineals, s'ha utilitzat el kernel RBF (Radial Basis Function), que projecta les dades a un espai de dimensió superior.

Hiperparàmetres explorats:

S'ha realitzat una cerca exhaustiva amb GridSearchCV utilitzant Stratified 5-Fold Cross-Validation, optimitzant el Macro F1-Score sobre 98 combinacions (490 fits totals). La Taula 3 descriu els hiperparàmetres avaluats:

Hiperparàmetre	Valors provats	Descripció
kernel	['linear', 'rbf']	Tipus de kernel per transformar l'espai.
C	[0.01, 100] (7 valors en escala logarítmica)	Paràmetre de regularització. C petit = marge ampli, C gran = marge estret.
gamma	[0.001, 10] (6 valors en escala logarítmica)	Coeficient del kernel RBF. Defineix la influència de cada punt d'entrenament.
class_weight	['balanced', {0:1, 1:2}]	Gestió del desbalanceig de classes: 'balanced' ajusta automàticament, {0:1, 1:2} penalitza el doble els errors en TRS.

Taula 3: Resum de l'espai de cerca d'hiperparàmetres per al model SVM.

Per gestionar el desbalanceig de classes, s'ha utilitzat el paràmetre class_weight, que ajusta com el model penalitza els errors en cada classe. class_weight='balanced' ajusta automàticament els pesos inversament proporcionals a la freqüència de classe.

Resultats de l'entrenament i iteracions

La configuració òptima identificada pel GridSearchCV combina C=0.046, gamma=0.0063, kernel RBF i class_weight={0:1, 1:2}, aconseguint un Macro F1 en cross-validation de 0.5977 (std=0.0167) i en validation de 0.5802. L'anàlisi dels resultats confirma que el kernel RBF supera clarament el lineal, evidenciant relacions no lineals entre els factors de predicció. Així mateix, la penalització manual {0:1, 1:2} ha demostrat ser més efectiva que l'ajust automàtic balanced.

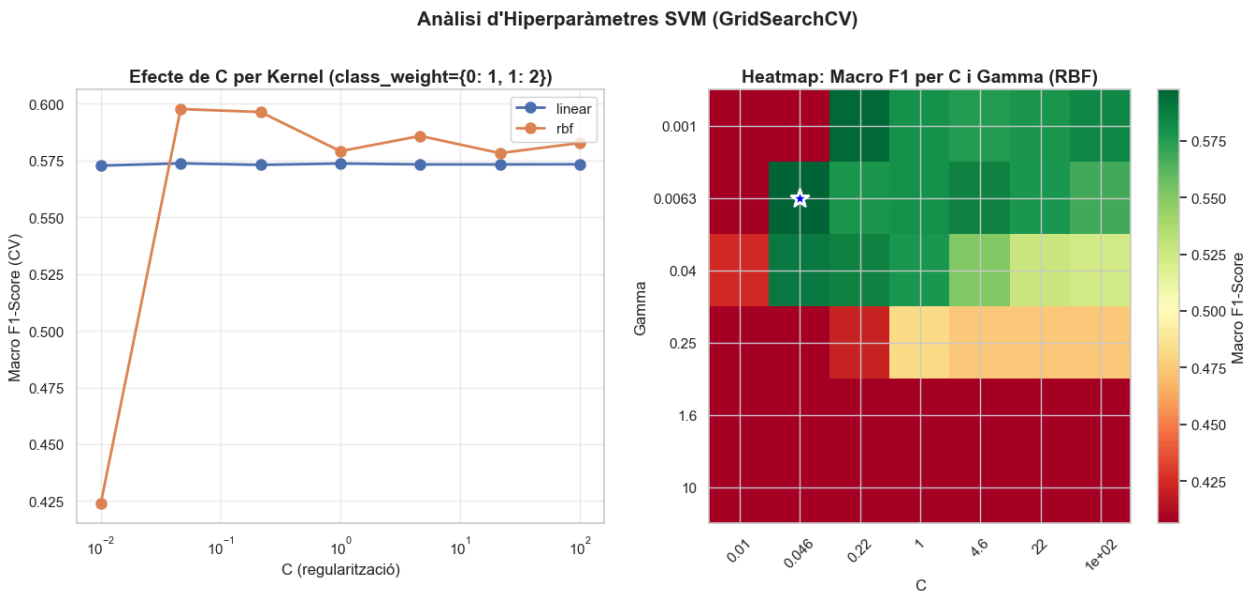

Figura 8: Esquerra: Macro F1-Score en validació creuada segons el valor de C per cada kernel amb class_weight={0:1, 1:2}. Dreta: Heatmap de la interacció entre C i gamma pel kernel RBF amb class_weight={0:1, 1:2}. L'estrella blava indica la combinació òptima.

El gràfic esquerre compara els dos kernels en funció de C, evidenciant la superioritat del RBF. El heatmap dret revela que la zona òptima (Macro F1 > 0.55) es concentra en C=[0.01-1] i gamma=[0.001-0.04]. Els valors molt baixos de la configuració seleccionada indiquen que les dades requereixen alta regularització i fronteres de decisió suaus per generalitzar adequadament.

Posteriorment a la cerca inicial, s'ha realitzat una cerca fina en la regió òptima (C=[0.02-1], gamma=[0.003-0.012], 50 combinacions), identificant C=0.03 i gamma=0.012 amb Macro F1 CV=0.5981. No obstant això, s'ha seleccionat el model de la cerca inicial perquè obté millor Macro F1 en validation (0.5802 vs 0.5796), indicant millor capacitat de generalització a dades no vistes i evitant ajust excessiu a les particions de la validació creuada.

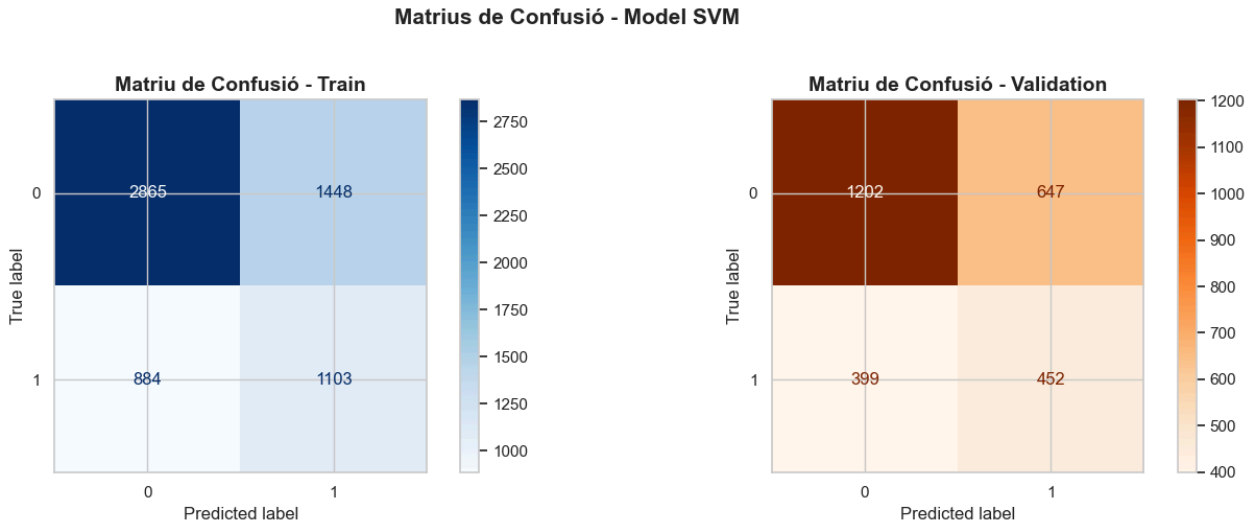

Figura 9: Matrius de confusió del model SVM amb configuració òptima. Esquerra: conjunt d'entrenament (6300 mostres). Dreta: conjunt de validació (2700 mostres). Les diagonals representen prediccions correctes. En validació, el model aconsegueix 1202 TN (65% especificitat) i 452 TP (53% sensibilitat), amb 647 FP i 399 FN.

Anàlisi d'overfitting i underfitting

El model presenta excel·lent generalització, amb gaps train-validation inferiors al 3% en totes les mètriques: Macro F1 (1.82%), F1 TRS (2.25%), Recall (2.40%), Precision (2.11%) i Accuracy (1.72%). La Figura 10 presenta la validation curve per al paràmetre C:

S'observa el comportament esperat: amb C < 0.01 (alta regularització) apareix underfitting amb Macro F1=0.4. El valor òptim C=0.046 (línia vertical vermella) se situa just després d'aquesta zona, maximitzant el validation score (0.58). Amb C > 10 (baixa regularització), mostra overfitting progressiu: el train score ascendeix fins a 0.85 mentre el validation score decau a 0.5.

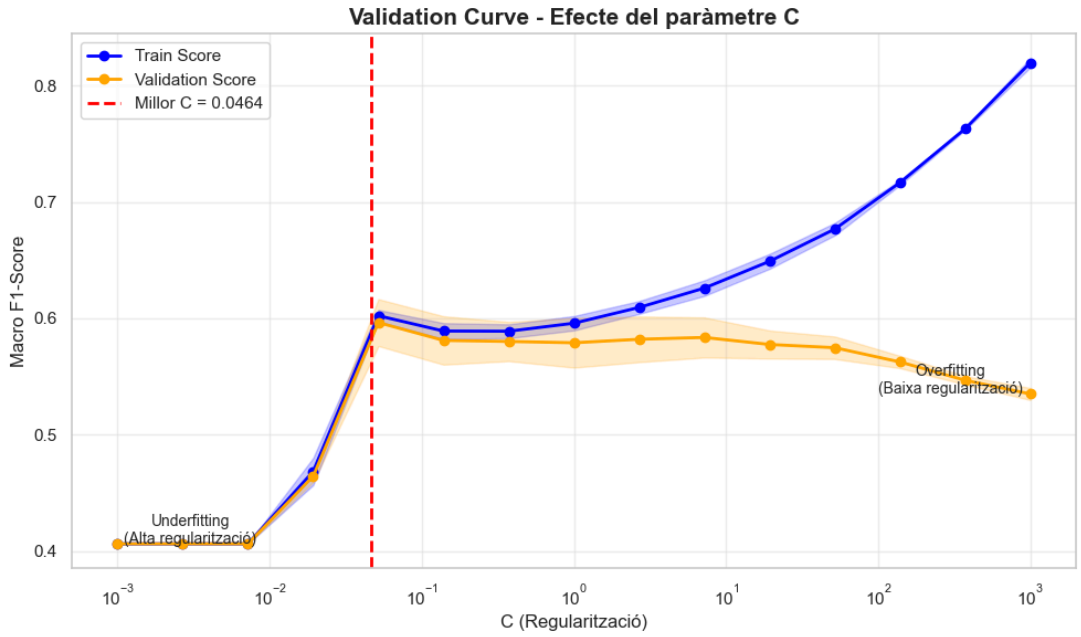

Figura 10: Validation curve mostrant l'efecte del paràmetre C en el rendiment. La línia vermella indica el valor òptim de C seleccionat per GridSearchCV.

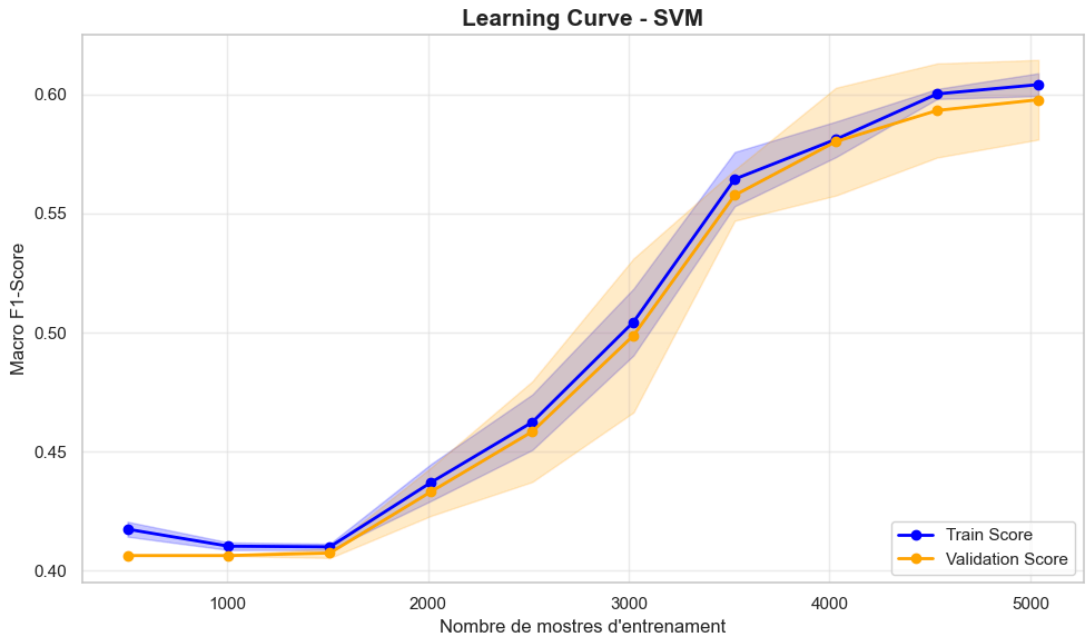

Figura 11: Learning curve del millor model SVM. La zona ombrejada representa ±1 desviació estàndard dels 5 folds de cross-validation.

La learning curve mostra que, amb menys de 1500 mostres, el model presenta underfitting. A partir de 2500 mostres, ambdues corbes convergeixen progressivament, indicant millor generalització. Amb el dataset complet (6300 mostres), el gap és de només 1.8%, i les bandes d'incertesa (desviació estàndard dels folds) es redueixen significativament. Aquesta tendència suggereix que incorporar dades addicionals milloraria marginalment el rendiment.

Un aspecte destacable és l'alt nombre de support vectors: 5772 (91.6% de les dades d'entrenament), distribuïts en 3849 NTRS i 1923 TRS. Aquest percentatge elevat reflecteix la complexitat intrínseca del problema de classificació TRS i la necessitat de considerar gairebé totes les mostres per definir la frontera de decisió òptima, coherent amb la baixa regularització aplicada.

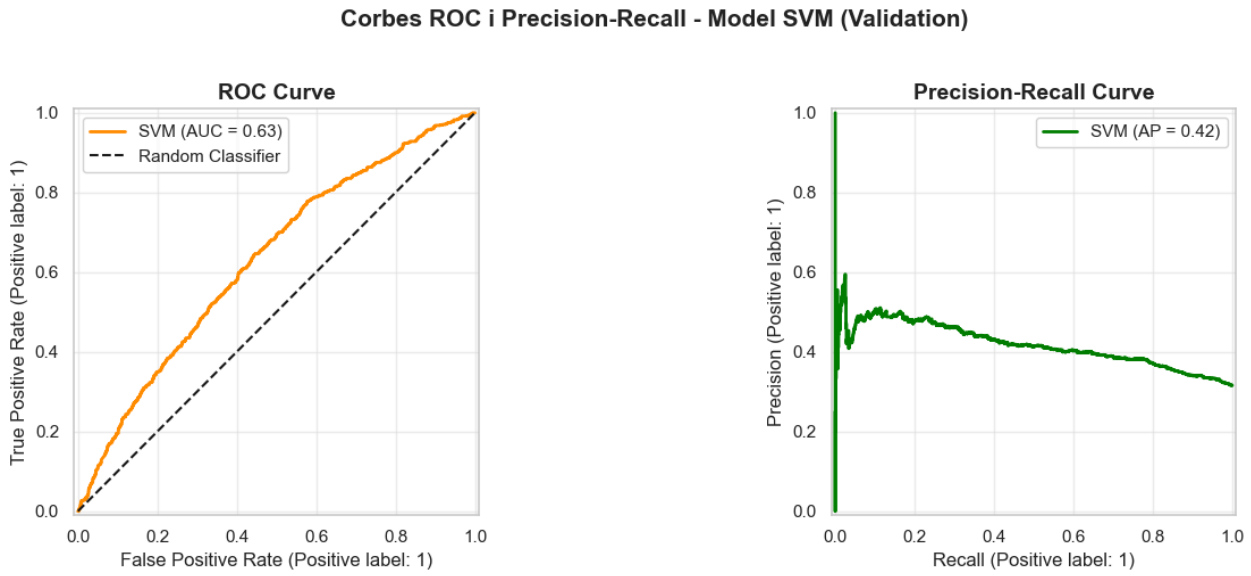

Figura 12: Corbes d'avaluació del model SVM en validation. Esquerra: Corba ROC que avalua la capacitat discriminativa del model. Dreta: Corba Precision-Recall.

La corba ROC (AUC=0.63) indica capacitat de discriminació moderada, superior al classificador aleatori (AUC=0.5). La corba Precision-Recall (AP=0.42) revela que la precisió decau ràpidament a mesura que augmenta el recall, a causa del desbalanceig de classes.

Optimització del threshold

Per defecte, SVM classifica amb threshold 0.5 sobre les probabilitats. No obstant això, en problemes amb classes desbalancejades, aquest threshold pot no ser el millor. S'ha realitzat una cerca exhaustiva del threshold òptim avaluant valors en el rang [0.30, 0.70] amb intervals de 0.02, calculant per cada threshold el Macro F1, F1 TRS, Recall TRS i Precision TRS sobre el conjunt de validation.

El threshold òptim identificat és 0.36, que aconsegueix un Macro F1 de 0.5829, representant una millora del +7.82% respecte al threshold per defecte 0.5 (Macro F1 = 0.5047). A més, augmenta significativament la sensibilitat del model, detectant gairebé el doble de pacients TRS a cost d'un increment moderat de falsos positius (Precision baixa de 44% a 42%). Això és una millora molt positiva en el context clínic, on prioritzem no perdre diagnostics TRS.

3.3. Model 2: XGBoost

XGBoost (Extreme Gradient Boosting) és un algorisme d'ensemble basat en gradient boosting, que entrena arbres de decisió seqüencialment, on cada nou arbre corregeix els errors dels anteriors.

Hiperparàmetres explorats

S'ha utilitzat RandomizedSearchCV amb 30 iteracions i Stratified 5-Fold Cross-Validation, explorant eficientment un espai de >100.000 combinacions possibles (150 fits totals). La Taula 4 descriu els 10 hiperparàmetres avaluats:

Hiperparàmetre	Valors provats	Descripció
n_estimators	[100, 200, 300]	Nombre d'arbres. Més arbres milloren rendiment però incrementen cost computacional.
max_depth	[3, 4, 5, 6]	Profunditat màxima per arbre. Controla complexitat del model i propensió a overfitting.
learning_rate	[0.01, 0.05, 0.1]	Taxa de shrinkage. Valors baixos = aprenentatge més estable però requereixen més arbres.
min_child_weight	[1, 3, 5]	Suma mínima de pesos en fulles. Major valor = model més conservador
subsample	[0.7, 0.8, 0.9]	Fracció de mostres per arbre. Redueix variància.
colsample_bytree	[0.7, 0.8, 0.9]	Fracció de features per arbre. Promou diversitat entre arbres.
gamma	[0, 0.1, 0.2]	Guany mínim per fer split. Regularització de complexitat.
reg_alpha	[0, 0.1, 0.5]	Regularització L1. Promou selecció de features (sparsity).
reg_lambda	[1, 1.5, 2]	Regularització L2. Shrinkage de pesos de les fulles.
scale_pos_weight	[1.5, 2.0, 2.5]	Pes classe positiva (TRS). Compensa desbalanceig de classes.

Taula 4: Hiperparàmetres explorats per al model XGBoost.

Resultats de l'entrenament i iteracions

La configuració òptima identificada pel RandomizedSearchCV combina n_estimators=100, max_depth=4, learning_rate=0.01, subsample=0.8, colsample_bytree=0.7, gamma=0, reg_alpha=0.1, reg_lambda=1.5, min_child_weight=1 i scale_pos_weight=2.0, aconseguint un Macro F1 en cross-validation de 0.5894 (std=0.0172) i en validation de 0.5805. Les millors configuracions presenten Macro F1 CV entre 0.586-0.589, amb desviacions estàndard <0.017, indicant una zona òptima clara. Les configuracions amb max_depth=4-5 superen consistentment max_depth=6 (overfitting) i max_depth=3 (underfitting). El learning_rate=0.01 és òptim per tots els millors models, confirmant que valors baixos milloren la generalització malgrat requerir més arbres.

Posteriorment s'ha realitzat una segona cerca fina amb 50 iteracions en la regió òptima identificada, aconseguint Macro F1 CV=0.5914 amb més regularització (gamma=0.5, reg_alpha=0.5, min_child_weight=5). No obstant això, la configuració inicial ha estat seleccionada perquè obté millor Macro F1 en validation (0.5805 vs 0.5787), indicant millor capacitat de generalització a dades no vistes i evitant ajust excessiu a les particions de la validació creuada.

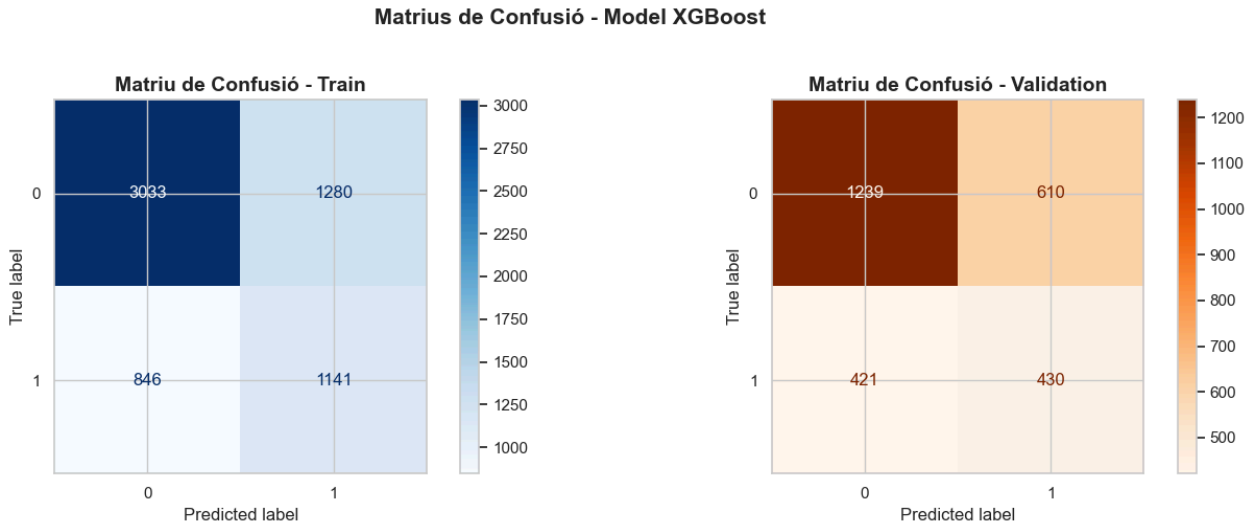

Figura 13: Matrius de confusió del model XGBoost amb configuració òptima. Esquerra: conjunt d'entrenament (6300 mostres). Dreta: conjunt de validació (2700 mostres). Les diagonals representen prediccions correctes. En validació, el model aconsegueix 1239 TN (67% especificitat) i 430 TP (51% sensibilitat), amb 610 FP i 421 FN.

Anàlisi d'overfitting i underfitting

El model presenta bona generalització, amb un gap train-validation de 4.86% en Macro F1, el que considerem acceptable. Tot i això, les mètriques específiques de la classe TRS mostren gaps lleugerament superiors: F1 TRS (6.29%), Recall (6.89%) i Precision (5.78%), per tant, identifiquem un lleuger overfitting.

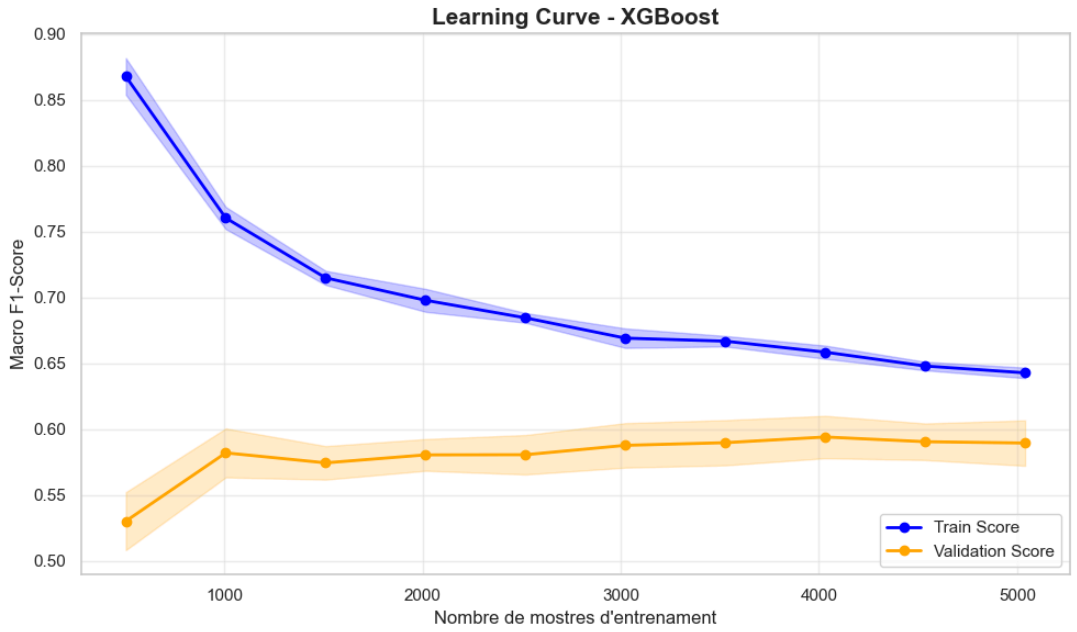

Figura 14: Learning curve del millor model XGBoost. La zona ombrejada representa ±1 desviació estàndard dels 5 folds de cross-validation.

La learning curve mostra que, a mesura que augmenta el nombre de mostres d'entrenament, la corba de validation millora progressivament i la corba de train decreix, indicant una reducció gradual de l'overfitting. Amb el dataset complet (6300 mostres), les corbes mantenen un gap de aproximadament 5%, i significativament, no arriben a convergir completament. La corba de validation mostra encara tendència ascendent al final, suggerint que el model beneficiaria d'incorporar dades addicionals que probablement millorarien el rendiment de generalització. Les bandes d'incertesa es redueixen significativament amb més dades, sobretot amb el conjunt train, indicant estimacions més estables del rendiment.

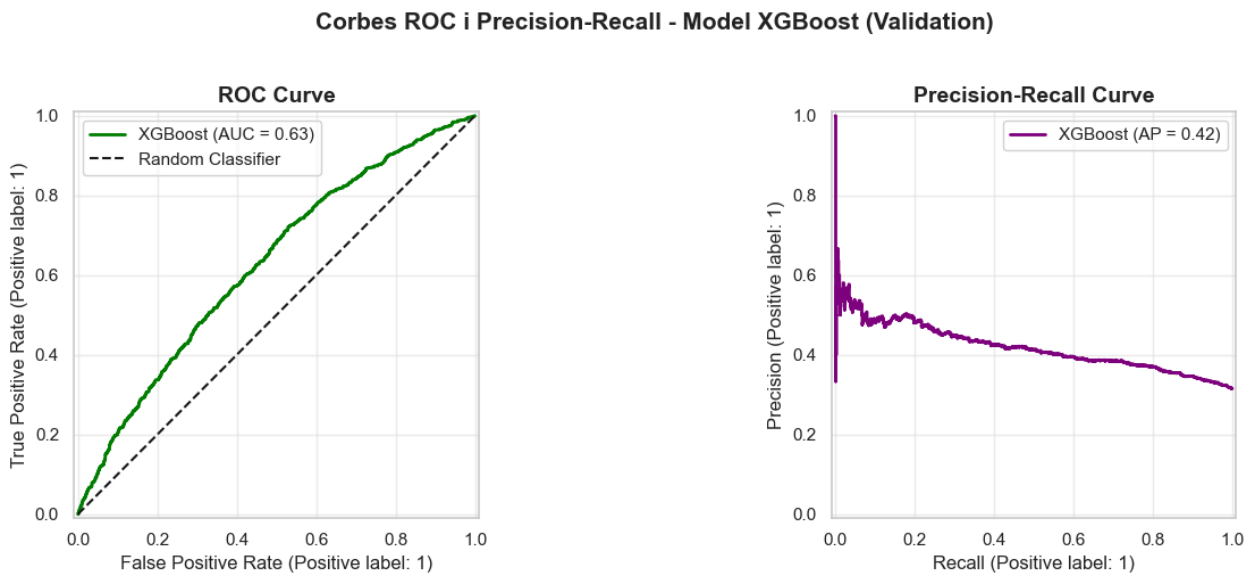

Figura 15: Corbes d'avaluació del model XGBoost en validation. Esquerra: Corba ROC que avalua la capacitat discriminativa del model (AUC=0.63). Dreta: Corba Precision-Recall (AP=0.42).

La corba ROC (AUC=0.63) indica capacitat de discriminació moderada, pràcticament idèntica al SVM (AUC=0.63), i superior al classificador aleatori (AUC=0.5). La corba Precision-Recall (AP=0.42) és també equivalent al SVM (AP=0.42), confirmant que ambdós models gestionen de forma similar el desbalanceig de classes. La precisió decau ràpidament a mesura que augmenta el recall.

Optimització del threshold

A diferència del SVM, l'anàlisi exhaustiva de thresholds en el rang [0.30, 0.70] revela que el threshold per defecte (0.5) ja és òptim per XGBoost, aconseguint el Macro F1 màxim de 0.5805. Els thresholds alternatius (0.48, 0.52) proporcionen configuracions diferents del trade-off Precision-Recall però no milloren el Macro F1 global.

Importància de característiques

L'anàlisi d'importància revela que *Initial_response* és clarament la variable dominant amb 18.6% d'importància relativa, confirmant la seva rellevància clínica observada a la secció 1.1. Les següents variables més importants són *Duration_untreated_psychosis* (5.6%), *Polygenic_risk_score* (5.1%), *Family_history* (4.6%) i *Ki_whole_striatum* (4.0%).

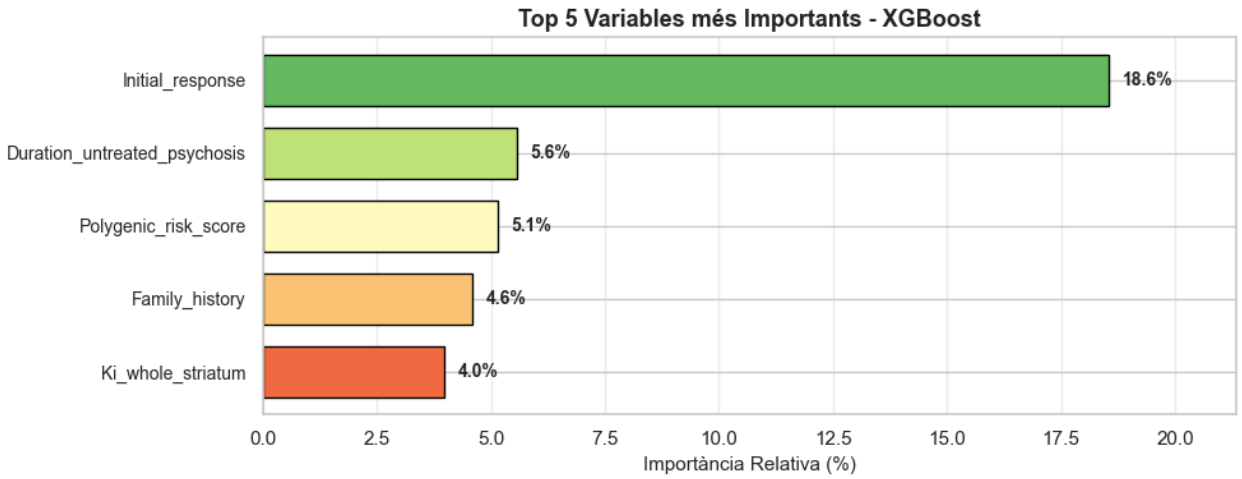

Figura 16: Ranking de les 5 variables més influents segons XGBoost (gain importance normalitzat). El color indica la importància relativa.

3.4. Model 3: Regressió Logística Custom (Minibatch Gradient Descent)

La regressió logística és un model de classificació lineal que estima la probabilitat d'una observació de pertànyer a una classe mitjançant la funció sigmoide. He implementat una versió custom des de zero seguint l'estil scikit-learn, amb descens de gradient per mini-batch, regularització L2, gestió del desbalanceig de classes mitjançant pos_weight i early stopping.

Hiperparàmetres explorats

He explorat 5 hiperparàmetres clau durant l'optimització del model (Taula 5). El paràmetre pos_weight s'ha calculat com la ràtio entre classes NTRS/TRS (2.17) per compensar el desbalanceig.

Hiperparàmetre	Valors	Descripció
learning_rate	[0.01, 0.05, 0.1]	Pas d'actualització del gradient. Controla la velocitat d'aprenentatge.
batch_size	[16, 32, 64, 128, 256]	Mida del mini-batch. Batches petits permeten actualitzacions freqüents; grans proporcionen gradients més estables.
l2	[0, 0.0001, 0.001, 0.01, 0.1]	Coeficient de regularització L2. Penalitza magnituds grans dels pesos per evitar overfitting.
max_iter	400	Nombre màxim d'iteracions (epochs).
tol	1e-4	Criteri d'aturada.
pos_weight	NTRS/TRS	Pes per classe TRS. Augmenta la penalització d'errors en la classe minoritària.

Taula 5: Hiperparàmetres explorats per al model de Regressió Logística Custom.

Resultats de l'entrenament i iteracions

He entrenat primer un model base amb hiperparàmetres per defecte (learning_rate=0.05, batch_size=64, l2=0.001) per establir una referència. Aquests valors inicials representen un punt intermedi equilibrat dins de cada rang. El model aconsegueix un Macro F1 en validation de 0.5720, amb un gap train-validation de 0.0117, indicant bona generalització des de l'inici.

Per validar la correctesa de la implementació custom, he comparat els resultats amb LogisticRegression de scikit-learn utilitzant paràmetres equivalents. La diferència en Val_Macro_F1 és de només 0.0036 (0.36%), confirmant que la implementació és correcta i funciona de manera equivalent a la versió optimitzada de scikit-learn.

<u>Estudi de la mida del mini-batch</u>

He analitzat l'impacte de 5 mides de mini-batch diferents en el rendiment del model, mantenint constants la resta d'hiperparàmetres. La Taula 6 i la Figura 17 mostren els resultats:

batch_ size	Train_Macro_F1	Val_Macro_F1	Val_F1_TRS	Val_Recall	Train_Val_Gap
16	0.5898	0.5720	0.4618	0.5441	0.0178
32	0.5825	0.5722	0.4771	0.5887	0.0103
64	0.5837	0.5720	0.4824	0.6052	0.0117
128	0.5914	0.5740	0.4741	0.5758	0.0174
256	0.5846	0.5683	0.4775	0.5981	0.0163

Taula 6: Rendiment segons mida de mini-batch. Batch_size=128 ofereix el millor Val_Macro_F1.

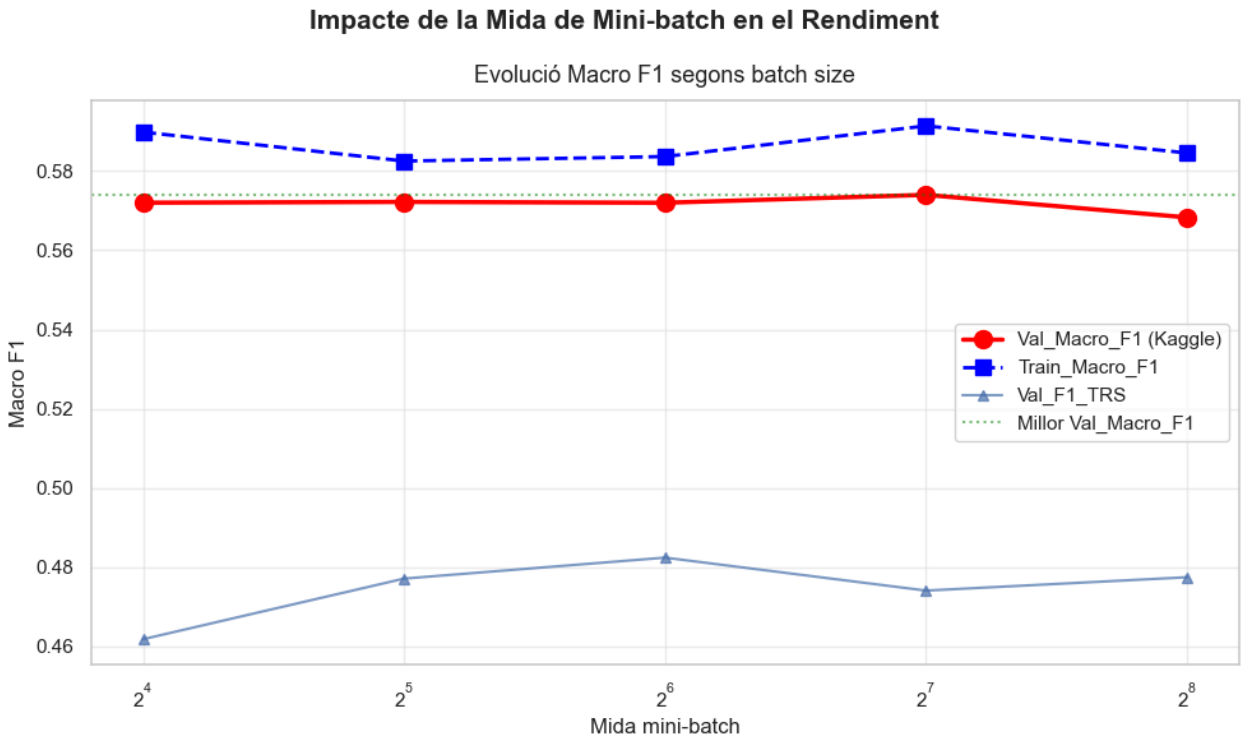

Figura 17: Impacte de la mida de Mini-batch en el rendiment.

Els resultats mostren diferències molt petites entre configuracions: el Val_Macro_F1 oscil·la només entre 0.568-0.574, indicant que l'efecte de la mida de batch és reduït . Batch_size=128 ofereix lleugerament el millor rendiment.

<u>Estudi de la regularització L2</u>

He avaluat l'efecte de la regularització L2 per controlar potencial overfitting. No s'ha explorat regularització L1 per evitar coeficients exactament zero i mantenir tota la informació disponible per interpretabilitat. La Figura 17 i la Taula 7 descriuen l'exploració i mostren els resultats:

L2	Train_Macro_F1	Val_Macro_F1	Train_Val_Gap
0.0	0.5842	0.5735	0.0106
0.0001	0.5845	0.5732	0.0113
0.001	0.5837	0.5720	0.0117
0.01	0.5851	0.5714	0.0137
0.1	0.5863	0.5669	0.0194

Taula 7: Rendiment segons coeficient de regularització L2

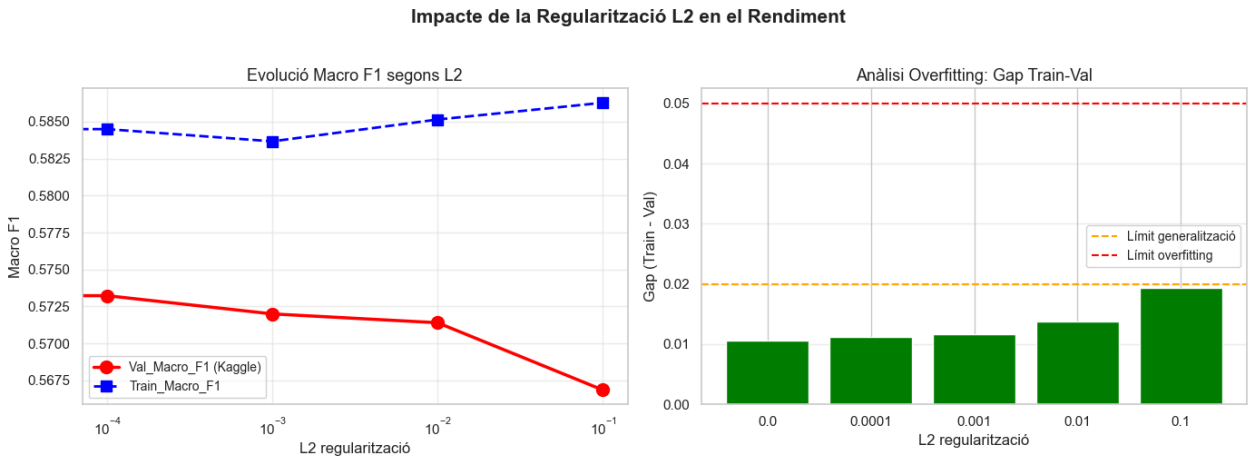

Figura 18: Impacte de la regularització L2 en el rendiment.

Sorprenentment, l2=0.0 (sense regularització) ofereix el millor Val_Macro_F1 (0.5735). Això és coherent amb els gaps train-validation consistentment baixos (<0.02) observats en tots els experiments, indicant que el model no presenta overfitting significatiu. La simplicitat del model lineal, combinada amb el pos_weight per gestionar el desbalanceig, proporciona suficient regularització implícita sense necessitar penalització L2 addicional. Amb valors de l2 elevats (≥0.1), s'observa underfitting progressiu amb Val_Macro_F1 que decau fins a 0.5669.

Finalment, he fet una cerca exhaustiva amb GridSearchCV utilitzant Stratified 5-Fold Cross-Validation sobre 27 combinacions d'hiperparàmetres. La configuració òptima identificada pel cross-validation combina learning_rate=0.05, batch_size=32 i l2=0.001, aconseguint un CV_Macro_F1 de 0.5790 ± 0.0179. Ha obtingut un Val_Macro_F1=0.5722, pràcticament idèntic al model base (diferència de només +0.0002).

Anàlisi d'overfitting i underfitting

El model final presenta excel·lent capacitat de generalització (Figura 20). Els gaps train-validation són molt baixos per totes les mètriques: Macro_F1 (1.03%), F1_TRS (1.51%),

Accuracy (0.87%) i Precision (1.07%). Únicament Recall mostra un gap lleugerament superior de 2.28%, però encara molt controlat.

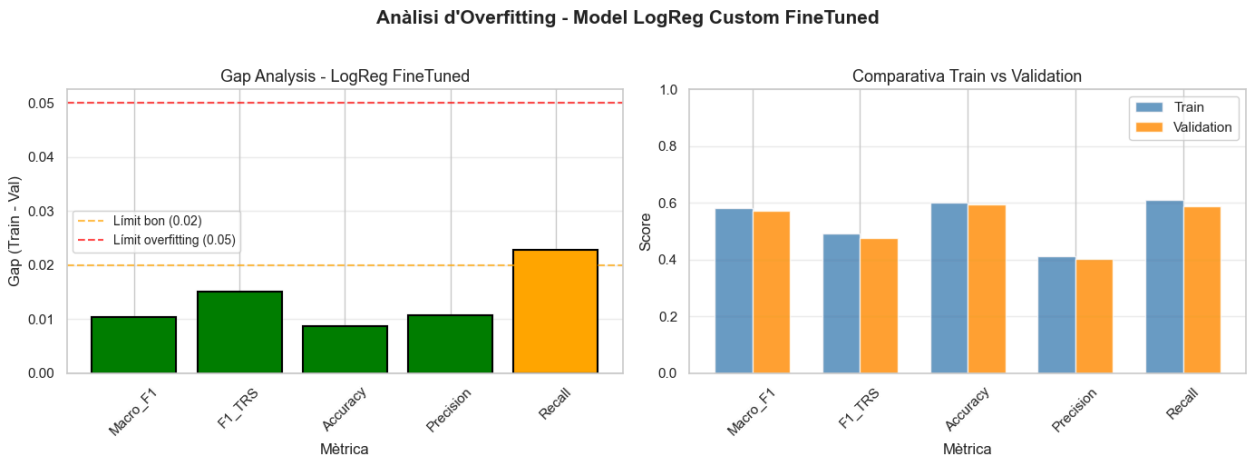

Figura 20: Anàlisi d'overfitting del model LogReg. Els gaps Train-Val per la majoria de mètriques són inferiors a 0.02 (zona verda), indicant una bona generalització.

Les matrius de confusió mostren que el model manté un comportament consistent entre train i validation. En validation, aconsegueix 1101 TN (60% especificitat) i 501 TP (59% sensibilitat), amb 748 FP i 350 FN. El model prioritza correctament la detecció de casos TRS (Recall=59%), coherent amb l'objectiu clínic de minimitzar falsos negatius.

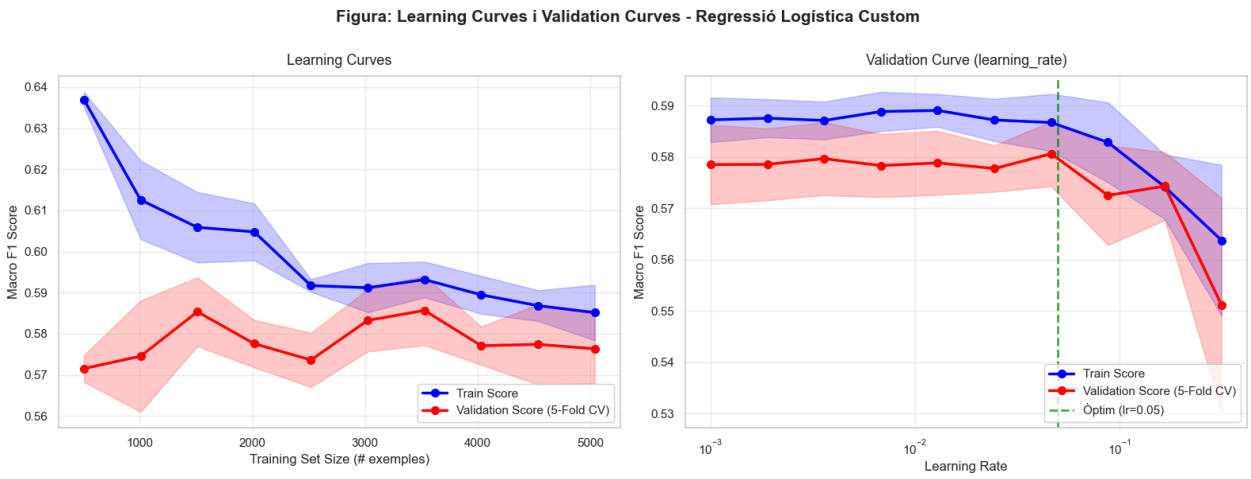

Figura 21: Esquerra: Learning Curves. Dreta: Validation Curve per learning_rate. La línia verda marca el valor òptim que maximitza el validation score.

La learning curve revela que, amb menys de 1500 mostres, el model presenta underfitting. A partir de 2500 mostres, ambdues corbes convergeixen progressivament fins arribar a un gap final de només 0.88% amb el dataset complet. Les corbes arriben gairebé a la convergència completa, suggerint que incorporar dades addicionals milloraria poc el rendiment. La validation curve per learning_rate mostra que el valor òptim (0.05) se situa just en la zona central del rang explorat, evitant convergència lenta (learning_rate<0.01) i inestabilitat (learning_rate>0.3).

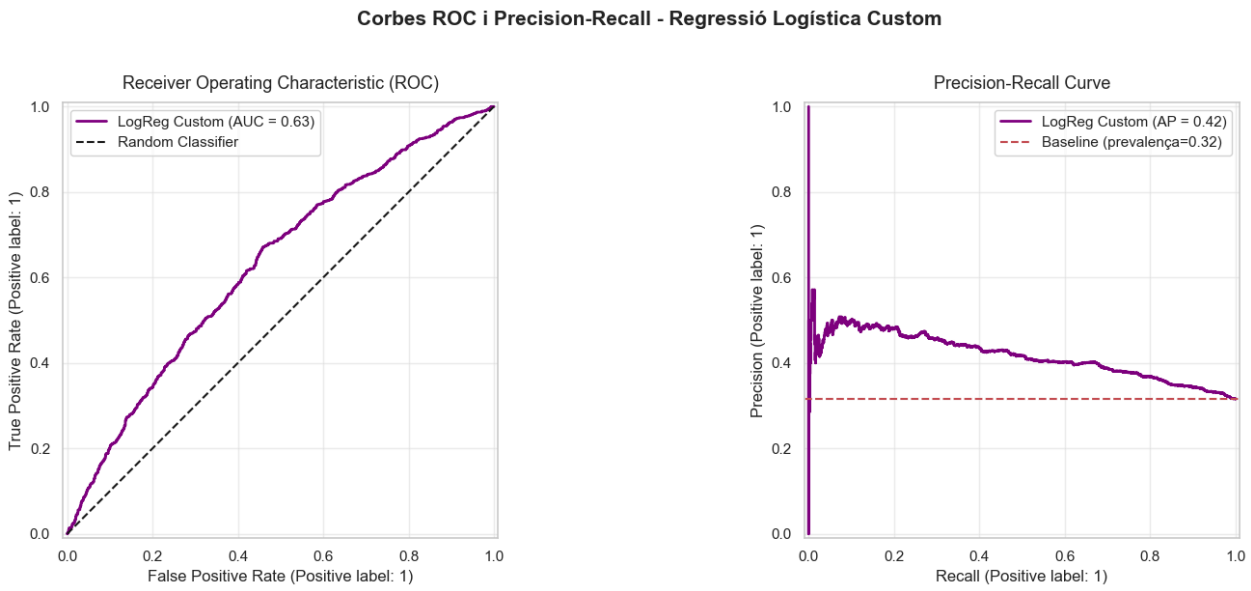

Figura 22: Esquerra: ROC-AUC. Dreta: PR-AUC.

El model assoleix un ROC-AUC=0.63 i PR-AUC=0.42 en validation, pràcticament idèntics als models SVM i XGBoost, confirmant capacitat discriminativa moderada similar entre els tres models.

Optimització del threshold

Per seguir ajustant el model, s'ha explorat 71 thresholds diferents en el rang [0.1, 0.8] per maximitzar el Macro F1 en validation. El threshold òptim identificat és 0.55, que aconsegueix un Macro F1 de 0.5876, representant una millora del +2.69% respecte al threshold per defecte.

Threshold	Val_Macro_F1	Val_F1_TRS	Val_Recall	Val_Precision
0.50	0.5722	0.4771	0.5887	0.4011
0.55	0.5876	0.4458	0.4642	0.4289

Taula 8: Comparativa threshold per defecte vs òptim.

Tot i que el Recall TRS disminueix (de 58.9% a 46.4%), la Precision TRS millora (de 40.1% a 42.9%), resultant en un Macro F1 global superior que tracta ambdues classes amb la mateixa importància.

Interpretació dels coeficients

Finalment, he analitzat els coeficients del model per identificar quines variables tenen major impacte en la predicció de TRS. La Figura 23 mostra les 15 variables més influents segons el valor absolut del coeficient:

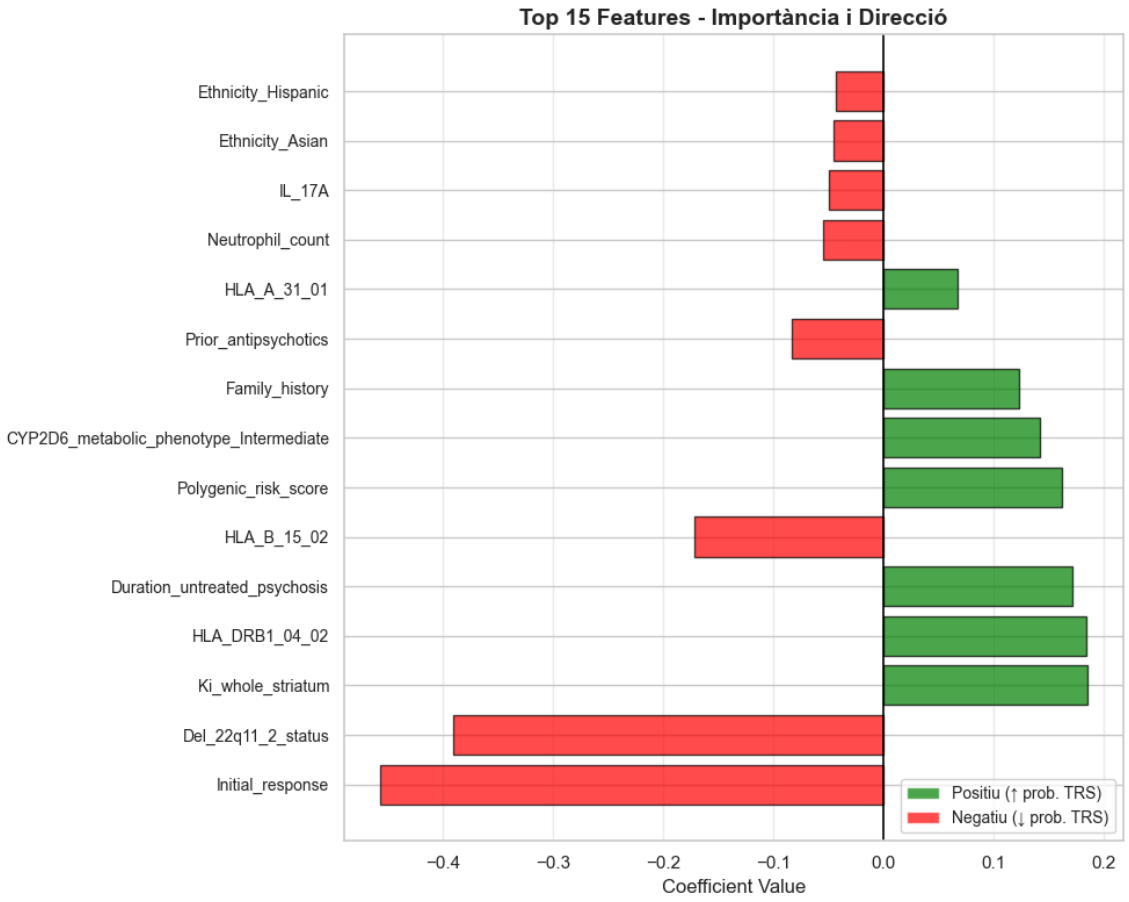

Figura 23: Top 15 factors amb coeficients més rellevants del model LogReg final.

El factor més important és *Initial_response* (coef=-0.457), amb el coeficient negatiu més fort. Pacients amb resposta inicial baixa tenen significativament major probabilitat de desenvolupar TRS, confirmant la rellevància clínica ja observada en l'anàlisi exploratori. En contrast, *Ki_whole_striatum* (coef=+0.186) presenta el tercer coeficient més alt en valor absolut però amb signe positiu, indicant que valors elevats d'aquest marcador de neuroimatge augmenten la probabilitat de TRS.

3.5. Comparativa de millors classificadors

Per tancar aquesta secció, he comparat els tres models utilitzant els seus thresholds òptims identificats mitjançant l'anàlisi exhaustiva per maximitzar el Macro F1 en validation. La Taula 9 i la Figura 24 mostren els resultats finals:

Model	Threshold	Val_Macro_F1	Val_F1_TRS	Val_Recall	Val_Precision
SVM	0.36	0.5829	0.4616	0.5194	0.4154
XGBoost	0.50	0.5805	0.4548	0.5053	0.4135
LogReg	0.55	0.5876	0.4458	0.4642	0.4289

Taula 9: Comparativa de rendiment dels tres models.

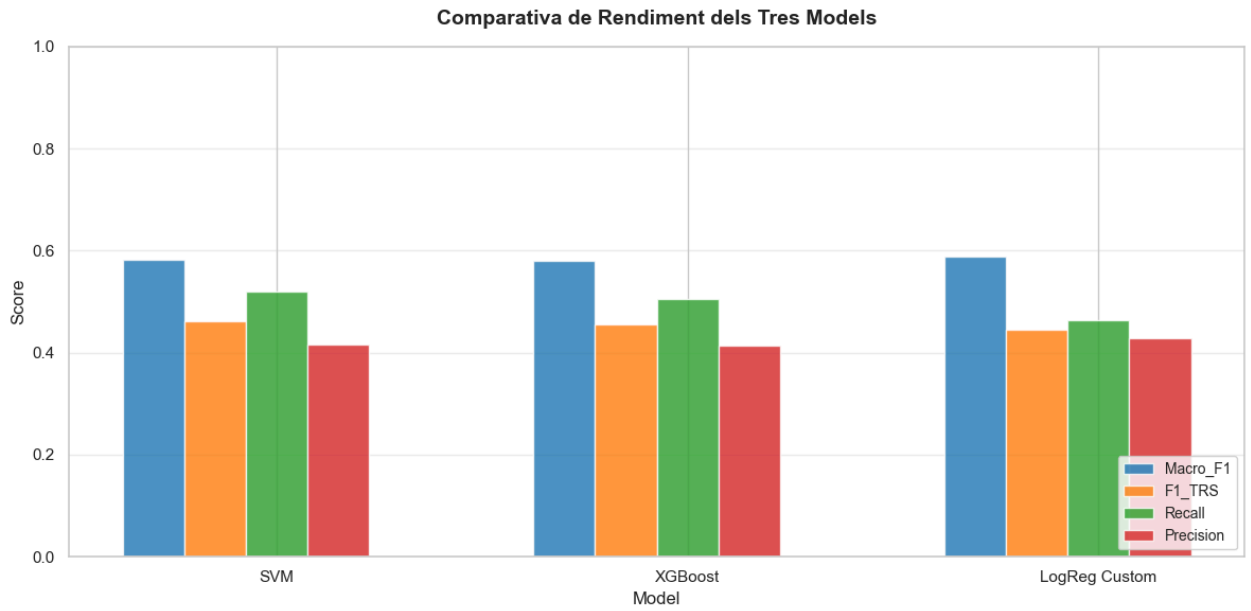

Figura 24: Comparativa de rendiment dels tres models.

El model de Regressió Logística Custom aconsegueix el millor rendiment amb Val_Macro_F1=0.5876, superant lleugerament l'SVM (0.5829) i l'XGBoost (0.5805). Les diferències són molt petites (<1%), indicant que els tres models tenen capacitat predictiva similar. LogReg Custom destaca per la seva millor Precision (0.4289), aconseguint el millor equilibri entre ambdues classes mesurades pel Macro F1. L'SVM presenta el millor Recall (0.5194), detectant més casos TRS però amb més falsos positius. XGBoost se situa en una posició intermèdia amb rendiment lleugerament inferior.

4. Selecció del model

He seleccionat el model de Regressió Logística Custom com a model final per aquest projecte. Com ja s'ha vist a la comparació, aquest tercer model aconsegueix el millor rendiment en validation i proporciona el millor equilibri entre Precision i Recall per detectar casos TRS.

Tot i que en contextos clínics és prioritari maximitzar el Recall (detectar tots els pacients TRS per no perdre casos que requereixin tractament específic), he prioritzat l'equilibri entre ambdues classes mesurat pel Macro F1. La raó és que un model amb Recall alt però Precision molt baixa generaria massa falsos positius, classificant incorrectament pacients NTRS com a resistents al tractament.

En segon lloc, la regressió logística és un model lineal altament interpretable. A diferència de l'SVM amb kernel RBF (5772 support vectors, 91.6% de les dades) o l'XGBoost (100 arbres seqüencials amb splits complexos), la regressió logística proporciona coeficients directament interpretables que quantifiquen l'impacte de cada variable en la probabilitat de TRS. Aquesta

alta interpretabilitat és molt útil en el context mèdic del problema, i ofereix informació addicional que els altres models no.

El model lineal presenta una complexitat molt baixa (30 paràmetres, un per variable) comparada amb l'SVM (5772 support vectors) o l'XGBoost (≈12,000 paràmetres estimats considerant 100 arbres × max_depth=4 × features). Això es tradueix en entrenament ràpid.

Finalment, el model demostra excel·lent capacitat de generalització amb gaps train-validation consistentment baixos en totes les mètriques. Les learning curves mostren convergència gairebé completa, indicant que el model no presenta ni overfitting ni underfitting significatiu. En contrast, l'XGBoost encara mostra tendència a millorar amb més dades (gap=4.86%, corbes no convergides).

Pel que fa a les limitacions, el model assumeix relacions lineals entre variables i la probabilitat de TRS. Això significa que no captura interaccions complexes o efectes no-lineals que sí detecten models com XGBoost o SVM amb kernel RBF. No obstant això, els tres models obtenen ROC-AUC similar (0.63), indicant que aquesta informació no-lineal addicional no aporta millores substancials en aquest problema. A més, la capacitat discriminativa és moderada (PR-AUC=0.42), reflectint que predir TRS amb les variables disponibles és intrínsecament difícil. Probablement calen variables addicionals per millorar significativament les prediccions.

<u>Validació externa de Kaggle:</u>

El model ha obtingut un Macro F1=0.57 en el conjunt d'avaluació de Kaggle, lleugerament inferior al Val_Macro_F1=0.5876 obtingut en validation. Aquesta diferència de -3% indica bona capacitat de generalització a dades externes completament noves. La petita degradació és normal i esperada, reflectint possibles diferències entre el conjunt de validation intern (2700 mostres) i l'avaluació externa de Kaggle (1000 mostres noves). Aquesta consistència confirma que el model no està sobreajustat i que les decisions metodològiques han estat correctes.

5. Model Card

He completat la documentació tècnica i ètica del model final utilitzant VerifyML Model Card Toolkit. La Model Card generada inclou informació detallada sobre el model, les seves capacitats, limitacions i consideracions ètiques.

Model Details: Inclou la descripció tècnica completa del model (arquitectura de regressió logística custom amb minibatch gradient descent), els hiperparàmetres finals seleccionats amb GridSearchCV, les mètriques de rendiment obtingudes en cross-validation, validació interna i Kaggle, i la interpretabilitat dels coeficients. També especifica la versió del model, propietaris, llicència acadèmica i referències al dataset original i competició de Kaggle.

Considerations: Documenta les consideracions ètiques identificades durant el desenvolupament, com el risc de biaix de selecció, la gestió de falsos negatius (que retarden el

tractament adequat) i falsos positius (que exposen innecessàriament a tractaments alternatius). Per cada risc s'ha especificat una estratègia de mitigació concreta.

Limitations: Detalla les limitacions tècniques del model (linealitat, capacitat discriminativa moderada amb ROC-AUC=0.63, precision del 42.9%) i les limitacions de context d'ús. S'explicita clarament que es tracta d'un projecte acadèmic sense validació clínica i que no s'ha d'utilitzar per diagnòstic real.

Use Cases: Diferencia tres tipus de casos d'ús: l'ús apropiat actual (projecte acadèmic educatiu), l'ús potencial hipotètic que requeriria validació clínica rigorosa (eina de suport per identificar pacients d'alt risc), i els usos no apropiats (diagnòstic clínic directe sense supervisió mèdica).

Model Parameters & Data: Descriu detalladament els datasets d'entrenament (6,300 mostres, 68% NTRS) i validació (2,700 mostres, 30%), especificant les 29 variables finals resultants del preprocessament (17 numèriques normalitzades, 6 binàries originals, 6 derivades de one-hot encoding). Inclou visualitzacions de la distribució de classes i de la variable més rellevant (Initial_response).

Quantitative Analysis: Presenta totes les mètriques de rendiment de forma exhaustiva, comparant resultats amb threshold per defecte (0.5) i threshold òptim (0.55), incloent Macro F1, F1 per classe TRS, Recall, Precision, Accuracy i ROC-AUC. També documenta el gap de generalització train-validation (1.03%) i els resultats de cross-validation. Incorpora visualitzacions amb la matriu de confusió i la corba ROC.

Finalment, la Model Card s'ha exportat en dos formats (Markdown i HTML) per facilitar la seva consulta.

Conclusions

Aquest projecte ha implicat l'aplicació completa d'un procés d'aprenentatge supervisat per a la predicció d'esquizofrènia resistent al tractament (TRS), des de l'exploració inicial de dades fins a la documentació ètica del model final.

El model seleccionat, una regressió logística custom implementada amb descens de gradient per mini-batch, ha assolit un Macro F1-Score de 0.5876 en validació interna amb threshold optimitzat (0.55), mostrant excel·lent capacitat de generalització amb un gap train-validation de només 1.03%. La validació externa en Kaggle ha confirmat aquesta robustesa amb un Macro F1 de 0.57, representant una degradació del 3% que indica que el model generalitza adequadament a dades completament noves.

L'anàlisi comparativa entre els tres models entrenats (SVM, XGBoost i Regressió Logística) ha revelat que, malgrat assolir rendiments similars (diferències inferiors al 1.5% en Macro F1), la regressió logística ofereix el millor equilibri entre rendiment, interpretabilitat i simplicitat computacional. La interpretació dels coeficients ha permès identificar *Initial_response* com el

predictor més rellevant (coef=-0.457), confirmant la hipòtesi clínica que la resposta inicial al tractament és un factor crític per predir resistència a llarg termini.

Tot i els resultats satisfactoris, el projecte ha evidenciat les limitacions intrínseques del problema. La capacitat discriminativa moderada (ROC-AUC=0.63) i la precision del 42.9% indiquen que aproximadament el 57% de les prediccions positives són falsos positius. Aquesta limitació reflecteix la complexitat del fenomen clínic de la resistència al tractament, que depèn de factors multifactorials no completament capturats per les variables disponibles.Futures millores podrien incloure l'exploració de més models, la incorporació de dades temporals que capturin l'evolució dels pacients, i la validació en grups de pacients externes amb diversitat demogràfica i geogràfica per detectar possibles biaixos.

Concloc per tant, que el projecte ha complert satisfactòriament els objectius acadèmics plantejats, demostrant la capacitat d'aplicar tècniques d'aprenentatge automàtic vistes a classe a un problema real.